


32B Sınıfı İş İstasyonu

Donanım · Görsel Analiz · Bütçe



0 Ne deđiřti

70B kararından vazgeçtiniz. Bu, bütçenin dörtte üçünü deđil, **üçte ikisini** geri getiriyor — ve geri gelen para vitrin kasaya, hologram panele ve yedeklemeye harcanabilir hâle geliyor.

Ölçüt	Eski plan (70B · Yol B)	Yeni plan (32B)	Fark
Ekran kartı	2× RTX 3090 + NVLink	1× RTX 3090	−41.500
VRAM	48 GB	24 GB	−
Güç kaynađı	1200 W Platinum	850 W Gold	−5.000
Tepe güç	~850 W	~550 W	−300 W
Aylık elektrik	~560 TL	~380 TL	−180/ay
Isı sorunu	İki kart üst üste	YOK	−
Model	Llama 3.3 70B Q4	Qwen2.5 32B Q4	−
Hız	12-18 tok/sn	25-30 tok/sn	daha hızlı

KAZANILAN İKİ ŐEY

- Daha hızlı cevap.** 32B tek karta tamamen sığdıđı için, iki karta bölünmüş 70B'den *daha hızlı* cevap veriyor. Sesli konuşurken fark edilir bir Őey bu — 70B'de cümle başına bekleme var, 32B'de yok.
- Isı sorunu tamamen ortadan kalktı.** Çift kart kurulumlarının en yaygın arızası üstteki kartın hava alamamasıydı. Tek kart cam kasada rahat nefes alıyor — ve *dikey monte edildiđinde* vitrinin merkez parçası oluyor.

KAYBEDİLEN TEK ŐEY

Uzun akıl yürütme zincirlerinde 70B'nin bir miktar üstünlüğü var. Sizin iş akışınızda bunu göreceđinizi sanmıyorum, ama **tahmin etmeyelim**: `jarvis-karsilastir` aracıyla 14B ve 32B'yi kör olarak karşılařtırın (`docs/MODEL-KARSILASTIRMA.md`). Sonuç başa başsa bu 62.000 TL'yi de harcamayın.

1 Neden tam olarak 24 GB

24 GB rastgele seçilmiş bir sayı değil. 32B sınıfı bir modelin Q4 nicemlemesi **~20 GB** tutar; geriye kalan 4 GB, aynı anda çalışacak diğer modellere (mikrofon, gömme, küçük görü modeli) yetiyor. 16 GB'lık bir kart 32B'yi zorlar, 32 GB'lık kart parayı boşa harcar.

Model	Q4 boyutu	+8k bağlam	Toplam	24 GB'da
Qwen2.5 14B (bugünkü)	9 GB	1,5 GB	10,5 GB	BOL BOL
Qwen2.5 32B	19-20 GB	2 GB	21-22 GB	SIĞAR
Gemma 3 27B	16 GB	2 GB	18 GB	RAHAT
Llama 3.3 70B	43-45 GB	3 GB	46-48 GB	SIĞMAZ

24 GB nasıl paylaşılacak

Kart yalnızca ana modeli çalıştırmıyor. Gerçek bir oturumda bellek şöyle bölünür:



Yerleşik	VRAM	Ne işe yarar
Qwen2.5 32B Q4	20 GB	Ana muhakeme — teşhis, sohbet, araç kullanımı
Whisper small (STT)	0,6 GB	Mikrofon — konuşmayı metne çevirme
bge-m3 (gömme)	1,1 GB	RAG — belge arama vektörleri
Serbest	2,3 GB	Bağlam büyümesi ve tampon

GÖRÜ MODELİ AYNI ANDA SIĞMAZ


Fotoğraftan teşhis (Faz 6) için görü modeli gerekir. Qwen2.5-VL 7B **≈ 6 GB** — 32B ile birlikte 24 GB'a sığmaz. İki çözüm var:

- Model değiştirme:** fotoğraf gelince Ollama 32B'yi boşaltıp görü modelini yükler (10-20 sn gecikme), sonra geri döner. **ÜCRETSİZ**
- Küçük görü modeli:** 3B sınıfı bir model (~3 GB) 32B'nin yanında kalıcı durur. Daha zayıf ama *anında*.

Bu, 24 GB'ın tek gerçek sınırı. Bilerek kabul ediyoruz — alternatifi 466.000 TL'ydi.

2 Sistem nasıl görünecek

Aşağıdaki çizim şematiktir — ölçekli teknik resim değil, yerleşim planıdır. Amaç, parçaların cam arkasında nereye geleceğini ve neyin görüneceğini göstermek.




Şekil 1 — Önden görünüm. Cam panelin arkasında görünen ana parçalar: dikey monte ekran kartı, Neural Core ekranı ve fan yerleşimi.

TASARIMIN ÜÇ KARARI

- 1. Ekran kartı dikey.** Yatay takılsaydı cam arkasından yalnızca sırtı görünürdü. Dikey monte edilince fanları öne bakar ve vitrinin merkez parçası olur — üstelik hava alması da kolaylaşır.
- 2. Ekran sol üstte.** Ekran kartının üstünde, göz hizasına yakın. Neural Core dairesel olduğu için kare bir panelde ortalanmış duruyor.
- 3. Giriş fanları kartın yüzüne bakıyor.** Yan panelden gelen hava doğrudan kartın emiş yüzeyine çarpar; ısınmış hava üstten çıkar. Bu, en kısa ve en verimli hava yolu.


3 Hava akışı ve hologram optiği



Şekil 2 — Yandan kesit. Soğuk hava alttan ve yandan girer, kartın üzerinden geçer, ısınıp üstten çıkar. Isınan hava zaten yukarı çıkar — akış yönü fizikle aynı tarafta.

Hologram nasıl çalışıyor

Pepper's Ghost: 150 yıllık bir sahne tekniği, bugünkü "hologram vitrinlerin" hepsinde bu var. Parlak bir ekran, 45 derece açıyla duran yarı geçirgen bir cama yansır; izleyici görüntüyü camın *arkasında*, *havada* görür.



Şekil 3 — Pepper's Ghost. Ekran aşağıda yatay durur; 45°'lik cam görüntüyü izleyiciye yansıtır ve görüntü camın arkasında asılı görünür.

NEDEN NEURAL CORE BUNUN İÇİN İDEAL

Pepper's Ghost'ta **siyah alanlar görünmez olur** — yalnızca parlak pikseller havada asılı kalır. Neural Core zaten koyu zeminde parlayan halkalardan oluşuyor; yani panelin mevcut tasarımı, hiç değiştirilmeden bu efekt için doğru olanı yapıyor. Yalnızca arayüzün "yalnızca Core" gösteren bir modu gerekiyor, o da yazılım tarafında birkaç saatlik iş.

4 Donanım listesi ve fiyatlar

Dört katman. Her katman kendi başına çalışan bir sistem bırakıyor; sonrakine geçmeseniz elinizde yarım bir şey kalmıyor.

Katman 1 — Çekirdek

ŞART

62.000 TL

32B modelin çalışması için gereken minimum. Bu katmandan sonra J.A.R.V.I.S. bugünkünden belirgin şekilde zeki olur.

Kalem	Seçim / model	TL
Ekran kartı	RTX 3090 24 GB · ikinci el, yerinde test	38.000
Güç kaynağı	850 W 80+ Gold · tam modüler	9.000
M.2 SSD	2 TB Gen4 NVMe	15.000
Ara toplam		62.000

Katman 2 — Vitrin kasa

27.900 TL

"Uzay sistem" görüntüsü bu katmanda ortaya çıkıyor. Termal olarak da kazanç — mevcut kasadan büyük ihtimalle daha iyi soğutur.

Kalem	Seçim / model	TL
Kasa	Lian Li O11 Dynamic EVO XL · 3 yüzü cam	15.000
Fan ×7	120 mm PWM · yüksek statik basınç	5.500
Fan çoğaltıcı	PWM hub · 8 kanal	400
Dikey kart kiti	PCIe 4.0 riser + braket	3.000
İç ekran	7-10 inç HDMI panel · Neural Core için	4.000
Ara toplam		27.900

Katman 3 — Konfor ve emniyet

16.500 TL

Şart değil ama biri gerçekten önemli: model yüklenirken gelen bir elektrik kesintisi dosyayı bozar.

Kalem	Seçim / model	TL
Sistem RAM	+2×16 GB DDR4 (ikinci el) → 64 GB	6.000
Harici disk	4 TB USB 3.2 HDD · model arşivi + yedek	6.000
CPU soğutucu	240 mm AIO veya iyi kule	4.500
Ara toplam		16.500

Katman 4 — Hologram

9.000 TL

Şekil 3'teki etki. En son yapılacak iş; makine çalışırken bir hafta sonu projesi.

Kalem	Seçim / model	TL
Yarı geçirgen cam	30×30 cm · %30-50 yansıtmalı beam splitter	3.000
Kaynak ekran	Parlak 10-13 inç panel	5.500
Montaj	45° braket + kablo	500
Ara toplam		9.000

Genel toplam

Katman	Ne kazandırır	Maliyet	Kümülatif
1 · Çekirdek	32B modeli tam hızda çalışır	62.000	62.000
2 · Vitrin kasa	Görünür, sergilenebilir makine	27.900	89.900
3 · Konfor	Yedekleme, RAM rahatlığı, sessizlik	16.500	106.400
4 · Hologram	Havada duran Neural Core	9.000	115.400
Tam proje		115.400	115.400

Korunan parçalar (yeniden alınmıyor)	Neden
Ryzen 7 5800X	Çıkarımda işlemci %5-10 doluluğu geçmez
Mevcut anakart	Tek kart için ek yuva gerekmiyor
Mevcut 32 GB DDR4	Yeter; 64 GB yalnızca rahatlık
RTX 3080 Ti 12 GB	Satın — ~25.000 TL eder, projeden düşer

GERÇEK NET MALİYET

3080 Ti'yi satarsanız tam projenin net maliyeti **≈90.000 TL**'ye iner. Yalnızca Katman 1 + 2 yaparsanız (ki yeter) **≈65.000 TL**.

Aylık işletme

Kullanım	Ortalama güç	Aylık kWh	Aylık TL
Sadece çalışırken açık (günde 3 sa)	~180 W	~45	195
7/24 boşa + günde 2 sa tam yük	~120 W ort.	~88	380
7/24 tam yük	~550 W	~396	1.710

4,32 TL/kWh (mesken kademe 2, 2026 EPDK tarifi).

5 Bu sistemle J.A.R.V.I.S. ne öğrenir

ÖNCE DÜRÜST CEVAP: MODEL KENDİ KENDİNE ÖĞRENMEZ

Yaygın bir yanlış anlama olduğu için baştan söyleyeyim: **Qwen2.5 32B'nin ağırlıkları sabittir.** Onunla ne kadar konuşursanız konuşun, model değişmez. Yarın da bugünkü kadar bilir.

"Öğrenme" bu projede üç ayrı mekanizmayla oluyor ve **ikisi zaten var:**

Mekanizma	Nasıl çalışır	Durum
1. Hafıza	Kalıcı bilgiler ve vaka kayıtları SQLite'ta durur, her turda bağlama eklenir. Model değişmez ama <i>bildikleri</i> birikir.	ÇALIŞIYOR
2. RAG	Belge havuzu (servis kılavuzları, şemalar, datasheet) vektör olarak aranır; ilgili parça soruyla birlikte modele verilir.	24 GB AÇAR
3. İnce ayar (LoRA)	Gerçek ağırlık değişimi. Kendi vaka kayıtlarınızla modeli eğitmek.	KISITLI

İNCE AYAR HAKKINDA GERÇEKÇİ OLALIM

24 GB'da **32B modeli ince ayar edemezsiniz** — QLoRA bile ~40 GB ister. İnce ayar edebilecekleriniz 7B ve 14B sınıfı modeller (~18 GB).

Ama şunu da söyleyeyim: **ince ayara muhtemelen hiç ihtiyacınız olmayacak.** İnce ayar üslup ve biçim öğretir, bilgi öğretmez. Bilgi için RAG doğru araçtır ve çok daha ucuz, çok daha kolay güncellenir. Bir servis kılavuzu değiştiğinde RAG'de dosyayı değiştirirsiniz; ince ayarda modeli baştan eğitmeniz gerekir.

5.1 Bugün çalışan yetenekler

Yetenek	Ne yapıyor
Sohbet + muhakeme	14B model · teknik sorulara detaylı cevap
Sistem telemetrisi	CPU/GPU sıcaklık, RAM, disk SMART · canlı
Terminal komutları	İzin listeli, kabuk kullanmadan, onay kapılı
Dosya işlemleri	Oku/yaz/listele · sır dosyaları mutlak yasak
Hafıza	Konuşma geçmişi + kalıcı bilgiler
Kimlik	Sizi tanır, hitap tercihinizi bilir
Ses (TTS)	ElevenLabs · panelde ve telefonda
Mikrofon (STT)	Yerel Whisper · ses buluta gitmez
Canlı panel	Neural Core + telemetri · telefondan erişilebilir

5.2 24 GB'ın açtığı yetenekler

A · Daha iyi muhakeme KATMAN 1

32B modelin 14B'ye göre üstün olduğu yer bilgi değil, **zincirleme akıl yürütme**. Teknik serviste bu şu demek: "DRAM LED'i yanıyor" gibi tek bir belirtiden, doğru sırada eleme yapan bir teşhis planı çıkarabilmek. 14B liste sayar; 32B

eleme yapar.

Ayrıca **daha az uydurur**. Küçük modellerin en sinir bozucu huyu, emin olmadığı yerde makul görünen bir şey uydurmasıdır — olmayan bir BIOS ayarı, yanlış bir LED anlamı. 32B'de bu belirgin şekilde azalıyor.

B · RAG — teknik doküman hafızası FAZ 3

Bu, sistemin en büyük sıçraması. Belgeleri yükler, J.A.R.V.I.S. onlardan **alıntı yaparak** cevap verir — hafızasından değil.

Yüklenebilecek	Ne kazandırır
Anakart servis kılavuzları	"Bu modelin DRAM LED'i ne demek" → belgeden kesin cevap
Boardview / şema dosyaları	Hangi hat nereye gidiyor, test noktaları
Datasheet'ler	Entegre pinout'ları, gerilim değerleri
Hata kodu tabloları	POST kodları, mavi ekran kodları
Kendi vaka notlarınız	"Geçen sene aynı belirtide şu çıkmıştı"
Garanti / fiyat listeleri	Müşteriye anında doğru rakam

NEDEN BU KADAR ÖNEMLİ

Bir dil modelinin en zayıf noktası, **bilmediğini bilmemesidir**. RAG bunu kökten değiştirir: cevap belgeden geldiği için hem doğrudur hem de *kaynağı gösterilebilir*. "Bunu nereden biliyorsun?" sorusuna sayfa numarası verebilen bir asistan, tahmin yürüten bir asistandan bambaşka bir şeydir.

Vektör verisi diskte durur — **binlerce sayfa belge 24 GB'ı zorlamaz**. Yalnızca 1,1 GB'lık gömme modeli VRAM'de yer tutar.

C · Görü — fotoğraftan teşhis FAZ 6

Telefonla çektiğiniz fotoğrafı panele yükleyip sorabilmek:

- **Anakart fotoğrafı** → şişmiş/akmış kondansatör, yanık iz, kırık soket pini
- **Mavi ekran fotoğrafı** → hata kodunu okuyup yorumlama
- **LED durumu** → hangi LED yanıyor, ne anlama geliyor (RAG ile birleşince güçlü)
- **Kablo/soket** → doğru takılmış mı
- **BIOS ekranı** → ayarları okuyup yorum

VRAM kısıtı yüzünden 32B ile aynı anda duramaz; ya model değişimi (10-20 sn) ya da küçük bir görü modeli. **Bu, 24 GB'ın kabul ettiğimiz tek ödünü.**

D · Diagnostic Brain — vaka hafızası FAZ 4

Her teşhis bir *vaka* olarak kaydedilir: belirti, denenenler, sonuç. Zamanla şuna dönüşür:

- "Bu belirtiyi **7 kez** gördük; 5'inde RAM, 1'inde GPU, 1'inde PSU çıktı."
- "Bu anakart modelinde **bu arıza tipik** — 3 vakada aynı."
- "Geçen sefer bu adımı atlamıştık, iki saat kaybetmiştik."

Bu **eğitim değil hafıza** — ama pratikte öğrenmeye en çok benzeyen şey. Ve sizin işinize özel: hiçbir hazır model sizin müşteri profilinizi bilmiyor.

E · Proaktif izleme FAZ 7

Servise gelen makinelerin SMART ve sıcaklık verisi kaydedilirse:

- "Bu diskin bekleyen sektörü 3 ayda 8'den 40'a çıkmış — müşteriye arayın"
- "Bu makine her yaz aynı sıcaklık sorununu getiriyor, macun ömrü dolmuş"

F · Ajanda ve iş takibi FAZ 7

Hangi makine kimde, ne zaman söz verildi, hangi parça bekleniyor. Panelin karşılama cümlesindeki "takviminizi kontrol edeyim mi" bu fazda **gerçek** olur — şu an sadece bir cümle.

5.3 Olgunluk tablosu

Yetenek	Bugün (12 GB · 14B)	24 GB · 32B sonrası
Teknik sohbet	İyi	Çok iyi — daha az uydurma
Teşhis planı çıkarma	Liste sayar	Eleme yapar
Belgeden cevap	YOK	RAG kaynak göstererek
Fotoğraftan teşhis	YOK	VAR model değişimiyle
Vaka hafızası	Ham konuşma	Yapılandırılmış vaka
Sesli konuşma	Var, biraz yavaş	Akıcı — 25-30 tok/sn
Proaktif uyarı	YOK	VAR
Telefondan tam erişim	Yazı + ses	+ fotoğraf yükleme

6 Ne yapamayacak

Bu bölümü bilerek koyuyorum. Bir sistemin ne yapabildiğini abartmak, onu kurduktan sonraki hayal kırıklığının tek sebebidir.

Yapamayacağı	Neden
Ölçüm yapmak	Multimetre, osiloskop, termal kamera yerine geçmez. Verdiğiniz veriyi yorumlar, kendi başına ölçmez.
Fiziksel muayene	Fotoğraftan mikro çatlak, soğuk lehim, kıl payı kısa devre görülmez. Kamera çözünürlüğü ve açısı her şeyi belirler.
Kesin teşhis garantisi	Her çıktı bir <i>hipotezdir</i> , ölçümle doğrulanmalıdır. Sistem bunu zaten söylüyor — panelde "bu bir varsayım" ifadesi tasarımın parçası.
20 yıllık sezgi	"Bu ses kulağıma yanlış geldi" türü bilgi modele aktarılamaz. Sizin katkınız burada yeri doldurulamaz.
Kendini eğitmek	Ağırlıklar sabit. Biriken şey hafıza ve belge, model değil.
İnternette canlı bilgi	Web erişimi eklenebilir ama <i> bilinçli olarak </i> ertelendi: dışarıdan gelen metin, prompt-injection açısından en riskli girdidir.
Aynı anda 32B + görü	24 GB'ın fiziksel sınırı. Model değişimi 10-20 saniye.

DOĞRU ZİHİNSEL MODEL

J.A.R.V.I.S. sizin yerinize teşhis koymaz; teşhis koyarken yanınızda duran, hiçbir şeyi unutmayan, bütün kılavuzları ezbere bilen bir çırak olur. Kararı siz verirsiniz, o eleme yapar, hatırlatır, kaynak gösterir ve atlanan adımı söyler.

Bu, "yapay zekâ teknisyen" iddiasından daha mütevazı ama çok daha gerçekçi — ve gündelik işte çok daha kıymetli.

7 Sıradaki adımlar

Bu hafta • 0 TL

- 32B'yi bugünkü kartta deneyin.** `ollama pull qwen2.5:32b-instruct-q4_K_M` (~20 GB). 12 GB'a sığmaz, RAM'e taşar, yavaş çalışır — ama *cevabın kalitesi* 3090'da alacağınızla aynıdır.
- Kör karşılaştırmayı çalıştırın:** `jarvis-karsilastir qwen2.5:14b-instruct qwen2.5:32b-instruct-q4_K_M`. Model adlarını görmeden 12 soruda tercih yapın, sonra anahtara bakın.
- Anakart modelini ve PSU watt'ını öğrenin** — `sudo dmidecode -t baseboard` ve kasanın içindeki etiket.

KARAR KURALI

Kör karşılaştırmada 32B **12 sorunun en az 8'inde** açık ara iyiye Katman 1'i alın. Başa başsa **almayın** — 14B işinizi görüyor, 62.000 TL'yi RAG ve vaka kaydı için harcanacak zamana ayırın.

Alım sırası

Sıra	Ne	TL	Neden bu sırada
1	Ekran kartı + PSU + SSD	62.000	Zekâ buradan geliyor; gerisi görünüş ve konfor
2	Kasa + fan + riser + iç ekran	27.900	Kart elde varken tek seferde monte edilir
3	RAM + harici disk + soğutucu	16.500	İhtiyaç hissettikçe, acelesi yok
4	Hologram	9.000	Sistem çalışırken hafta sonu projesi

Yazılım tarafı — ben ne yapacağım

İş	Donanım şartı	Durum
Panele "hologram modu" (yalnızca Core)	Yok	Bugün yapılabilir
Panele fotoğraf yükleme	Yok	Bugün yapılabilir
Ajanda / iş takibi modülü	Yok	Bugün yapılabilir
RAG (Chroma + bge-m3)	24 GB tercih edilir	Katman 1 sonrası
Vaka kaydı (Diagnostic Brain)	Yok	RAG ile birlikte
Görü modeli entegrasyonu	24 GB şart	Katman 1 sonrası
Telefonda mikrofon (HTTPS)	Yok	Tailscale kurulunca

DİKKAT: ÜÇ İŞ DONANIM BEKLEMİYOR

Ajanda modülü, panele fotoğraf yükleme ve hologram modu **bugün yapılabilir**. Kart almayı ertelerseniz bile bunlarla ilerleyebiliriz — hangisini önce istersiniz?

Ek · Fiyat kaynakları ve varsayımlar

Kalem	Fiyat	Kaynak / not
RTX 3090 24 GB (ikinci el)	38.000 TL	ABD 2.el ort. 820 \$ · TR ilan ortalaması
Lian Li O11 Dynamic EVO XL	14.999 TL	Akakçe / n11, 2026
Hyte Y70 (alternatif kasa)	17.139 TL	TR perakende, 2026
1 TB Gen4 NVMe	8.999 TL	incehesap · 2 TB için $\times \sim 1,7$
80+ Platinum PSU (giriş)	7.289 TL	Sinerji · 850 W Gold benzer bant
Elektrik, mesken kademe 2	4,32 TL/kWh	EPDK, Nisan 2026
USD/TRY	48,02	22 Ağustos 2026

Teknik varsayımlar

- Qwen2.5 32B Q4_K_M $\approx$ 19-20 GB ağırlık + ~ 2 GB bağlam (8k pencere)
- RTX 3090 üzerinde 32B Q4 $\approx$ 25-30 token/sn (tam VRAM'e sığdığında)
- Whisper small int8_float16 $\approx$ 0,6 GB · bge-m3 $\approx$ 1,1 GB
- Qwen2.5-VL 7B Q4 $\approx$ 6 GB — 32B ile aynı anda sığmaz
- 32B QLoRA ince ayarı $\approx$ 40 GB+ · 24 GB'da yapılamaz
- Tek 3090 sistemi tepe güç $\approx$ 550 W · boşta $\approx$ 90-120 W

UYARI

Bellek ve ekran kartı fiyatları 2026'da **haftalık** oynuyor (DDR5 endeksi Temmuz 2025'e göre $\approx 4,9$ kat). Bu tablolar karar vermek için yeterli, sipariş vermek için değil — alım gününde doğrulayın.

İkinci el 3090 alırken: 20 dk yük testi yapın, `nvidia-smi -q -d TEMPERATURE` ile bellek sıcaklığına bakın. Yükte $>100^{\circ}\text{C}$ ise termal pedler bitmiştir — pazarlık payıdır, ret sebebi değil.